

Introducción al Natural Language Processing (NLP)

Carlos Daniel Lopez Perez

Maestría en Estadística Aplicada

2024



- ① NLP
- ② Tokenizacion y normalizacion
- ③ Texto en estructuras de datos
- ④ Embeddings de palabras
- ⑤ Material de apoyo




- 1 NLP
- 2 Tokenizacion y normalizacion
- 3 Texto en estructuras de datos
- 4 Embeddings de palabras
- 5 Material de apoyo



Que es el Natural Language Processing

Natural Language Processing (NLP) o procesamiento del lenguaje natural es un area de investigacion multidisciplinaria cuyo objetivo es hacer que las maquinas 'entiendan' y procesen el lenguaje humano.



Usos del NLP

- Analisis de sentimientos
- Analisis de texto
- Asistentes Virtuales (siri, Alexa, Google Assistant)
- Traduccion de texto
- Chatbots
- Extraccion de informacion
- Reconocimiento de Entidades Nominadas
- Clasificación de Documentos



- 1 NLP
- 2 Tokenización y normalización
- 3 Texto en estructuras de datos
- 4 Embeddings de palabras
- 5 Material de apoyo



Definiciones y conceptos clave

- **Token** Unidad de un texto utilizada para analizar, procesar y comprender el texto.

The Tokenization

The Tokenization

The Tokenization

- **Documento** Un documento es una pieza de texto, que puede ser tan corta como una oración o tan larga como un libro. En NLP se trabaja con documentos para extraer tokens, información y patrones.
- **Corpus** Un corpus es una colección de documentos. Puede ser un conjunto de textos relacionados o diversos. Los corpus son esenciales para entrenar y evaluar modelos en NLP.

Definiciones y conceptos clave

- **Morfema** Es la unidad más pequeña de significado en una palabra. Puede ser una palabra completa o una parte de ella.

Un break able Un kind ness
break ing kind ly

- **Stop Words** son palabras comunes que a menudo se eliminan durante el análisis de texto debido a que tienen poco significado (por ejemplo, 'the', 'of', 'in', etc).

We are reading about Natural Language Processing Here

The field of Natural Language Processing is evolving everyday

Natural Language Processing making computers comprehend language data

Problemas asociados a la tokenizacion

Analicemos las siguientes oraciones:

- The capital of china is Beijing
- China's capital is Beijing
- I'll buy that if it doesn't cost too much
- Let's travel to Hong Kong from Beijing
- The name of the King is Kong
- A friend is meeting his M.S from Beijing
- Crash is about to crash



Stemming y Lematizacion

La lematización y el stemming son dos técnicas relacionadas en procesamiento de lenguaje natural (NLP) que buscan reducir las palabras a sus formas base o raíces.

Input	Stemming	Lematizacion
Flies	Fli	Fly
Happier, Happily	Happi	Happy
Computers, computing	Comput	Computer
Feet, better	Feet, better	Foot, good
Change, Changing, Changes, Changed, Changer	Chang	Change

POS Tagging y el contexto de las palabras

Part-of-Speech Tagging es un proceso que asigna a cada palabra en un texto una etiqueta correspondiente a su categoría gramatical o parte del discurso. Por ejemplo, sustantivo, verbo, adjetivo, adverbio, pronombre, preposición, conjunción, interjección, entre otras.



POS Tagging + Lemmatizacion

Se tiene la siguiente oracion: "We are putting in effort to enhance our understanding of Lemmatization"

Stemming

- "We are put in effort to enhanc our understand of lemmat"

Lematizacion + POS Tagging (WordNet)

- "We be put in effort to enhance our understand of Lemmatization"

Lematizacion + POS Tagging (Spacy)

- '-PRON- be put in effort to enhance -PRON- understand of lemmatization'

- 1 NLP
- 2 Tokenizacion y normalizacion
- 3 Texto en estructuras de datos
- 4 Embeddings de palabras
- 5 Material de apoyo



Bag of Words (BoW)

Es una técnica utilizada para representar documentos de texto como matrices. se trata el texto como un **conjunto desordenado de palabras** sin tener en cuenta la estructura gramatical ya que solo se considera la ocurrencia y frecuencia de las palabras, **no su orden**.

En terminos generales, consta de los siguientes pasos:

- 1 Tokenización
- 2 Normalizacion del corpus
- 3 Creación de Vocabulario
- 4 Conteo de tokens por documento
- 5 Creacion de la Matriz de Documento-Término

Bag of Words - Ejemplo

- 1 Tenemos el siguiente corpus:
 - We are reading about Natural Language Processing Here
 - Natural Language Processing making computers comprehend language data
 - The field of Natural Language Processing is evolving everyday

- 2 Se tokeniza y se quitan las stopwords:

['everyday', 'making', 'comprehend', 'data', 'field', 'reading',
'computers', 'language', 'processing', 'evolving', 'natural']

- 3 Se lematizan las palabras del corpus:

['everyday', 'make', 'comprehend', 'data', 'field', 'read',
'computers', 'language', 'process', 'evolve', 'natural']

Bag of Words - Ejemplo

- 4 Se indexa cada token del vocabulario

['read': 0, 'natural': 1, 'language': 2, 'computers': 3,
'everyday': 4, 'data': 5, 'evolve': 6, 'field': 7, 'process': 8,
'comprehend': 9, 'make': 10]

- 5 Se crea la matriz de documento-termino

$$\begin{bmatrix} 1 & 1 & 1 & 0 & 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 1 & 2 & 1 & 0 & 1 & 0 & 0 & 1 & 1 \\ 0 & 1 & 1 & 0 & 1 & 0 & 1 & 1 & 1 & 0 \end{bmatrix}$$

Limitaciones del BoW

- **Elimina la importancia de tokens**, o frases que ocurren muy raramente a pesar de que podrían ser significativas en la representación de ciertos documentos.
- La representación **no captura la semántica o significado** asociado con los tokens o frases en un documento, lo que significa que ignora el contexto en el que se utilizan.
- **El vocabulario puede crecer enormemente** en un corpus de texto grande, lo que resulta en vectores de gran tamaño para cada documento, lo que puede afectar negativamente el rendimiento del modelo.

Vectores TF-IDF

Term Frequency-Inverse Document Frequency Convierte documentos de texto en vectores numéricos, donde cada componente del vector representa la importancia de un término en un documento en relación con una colección de documentos.

TF (Term frequency)

Calcula la importancia del término en **todo el corpus** de documentos.

$$TF(word, doc) = \frac{\# \text{ de veces que } word \text{ aparece en } doc}{\# \text{ de palabras en } doc}$$

TF-IDF

IDF (Inverse Document Frequency)

Tiene en cuenta la frecuencia con la que aparece un término en un **documento**.

$$IDF(word) = \log\left(\frac{\# \text{ documentos en el corpus}}{\# \text{ de documentos que contienen a } word}\right)$$

TF-IDF

Se calcula el peso de la palabra *word* en el documento *doc* de la siguiente forma

$$weight(word, doc) = TF(word, doc) * IDF(word)$$

TF-IDF Ejemplo

Tomemos el siguiente corpus:

- The best italian restaurant cooks the best pasta
- American restaurant cooks the best hamburger
- Mexican restaurant cooks the best taco
- the best the best american restaurant

Palabra	TF				IDF	TF*IDF			
	d1	d2	d3	d4		d1	d2	d3	d4
italian	1/8	0/6	0/6	0/6	LOG(4/1)	0,075	0,000	0,000	0,000
restaurant	1/8	1/6	1/6	1/6	LOG(4/4)	0,000	0,000	0,000	0,000
cooks	1/8	1/6	1/6	0/6	LOG(4/3)	0,016	0,021	0,021	0,000
the	1/4	1/6	1/6	1/3	LOG(4/4)	0,000	0,000	0,000	0,000
best	1/4	1/6	1/6	1/3	LOG(4/4)	0,000	0,000	0,000	0,000
pasta	1/8	0/6	0/6	0/6	LOG(4/1)	0,075	0,000	0,000	0,000
american	0/8	1/6	0/6	1/6	LOG(4/2)	0,000	0,050	0,000	0,050
hamburger	0/8	1/6	0/6	0/6	LOG(4/1)	0,000	0,100	0,000	0,000
mexican	0/8	0/6	1/6	0/6	LOG(4/1)	0,000	0,000	0,100	0,000
taco	0/8	0/6	1/6	0/6	LOG(4/1)	0,000	0,000	0,100	0,000

Limitaciones del BoW

- TF-IDF aún depende del vocabulario y **no considera aspectos como la co-ocurrencia de términos**.
- **No tiene en cuenta el contexto asociado** con los términos ni la posición de un término en un documento.
- **El vocabulario puede crecer enormemente**, por tanto TF-IDF puede volverse lento con vocabularios grandes.

Similitud del coseno

Es una medida utilizada para determinar la similitud entre dos vectores en un espacio multidimensional. Se utiliza para medir la similitud entre dos documentos o textos **representados como vectores de términos**.

Dados dos documentos $\vec{A}$ y $\vec{B}$, su similaridad de coseno es:

$$\cos(\theta) = SIM_c(\vec{A}, \vec{B}) = \frac{\vec{A} \cdot \vec{B}}{\|\vec{A}\| \|\vec{B}\|} = \frac{\vec{A} \cdot \vec{B}}{\sqrt{\sum_{i=1}^N w_{iA}^2} \sqrt{\sum_{i=1}^N w_{iB}^2}}$$

Donde $\vec{A}$ y $\vec{B} \in \mathbb{R}^n$ con $T = \{t_1, \dots, t_n\}$. Cada dimension representa un termino y su valor nunca sera negativo. $\therefore SIM_c(\vec{A}, \vec{B}) = [0, 1]$

BoW vs TF-IDF Similaridad del Coseno


Teniendo el corpues anterior podemos calcular la similitud del coseno con las diferentes formas de vectorizar vistas:

- 1 The best italian restaurant cooks the best pasta
- 2 American restaurant cooks the best hamburger
- 3 Mexican restaurant cooks the best taco
- 4 the best the best american restaurant



Documento (i)	BoW $Sim_c(i, 4)$	TF-IDF $Sim_c(i, 4)$
1	0.82	0.0
2	0.77	0.50
3	0.65	0.0
4	1.0	1.0

Ruta





- 1 NLP
- 2 Tokenización y normalización
- 3 Texto en estructuras de datos
- 4 Embeddings de palabras
- 5 Material de apoyo




Embeddings de palabras

Es una técnica que consiste en asignar un vector a cada palabra.
Este vector guarda información semántica, lo que permite que pueda ser asociado o disociado a otros vectores (palabras).



Embedding - Word2vec

Word2vec es una técnica para el procesamiento de lenguaje natural publicada en 2013. El algoritmo Word2vec utiliza un modelo de red neuronal para aprender asociaciones de palabras a partir de un gran corpus de texto.



- 1 NLP
- 2 Tokenizacion y normalizacion
- 3 Texto en estructuras de datos
- 4 Embeddings de palabras
- 5 Material de apoyo



Material de apoyo

- Libro: Hands-On Python Natural Language Processing.
- Link: Codigos de apoyo del libro guia.
- Introduccion al NLP.
- Que son los Embeddings?.
- Word2vec Parameter Learning Explained.
- Arquitectura del positional encoding.
- Attention is all you need.

